

Derin Öğrenme

ERDEM ŞAHİNGÖZ 25221602006

GÖKALP TULUM

Bilgisayar Mühendisliği Anabilim Dalı

Bilgisayar Mühendisliği Programı

Haziran,2026

1. GİRİŞ

Günümüzde tıbbi görüntüleme teknolojileri, özellikle manyetik rezonans (MR) görüntüleme yöntemleri, hastalıkların erken teşhisinde kritik bir rol oynamaktadır. Beyin tümörü tespiti, insan gözüyle analiz edilmesi zor ve uzmanlık gerektiren bir süreçtir. Bu projede, derin öğrenme teknolojilerinin tıbbi alandaki potansiyelinden yararlanılarak, beyin tümörlerinin otomatik olarak tespiti hedeflenmiştir.

Çalışmada, nesne tespiti konusunda yüksek performans ve hız sunan, güncel bir mimari olan YOLOv8 kullanılmıştır. Projenin temel amacı, "Brain Tumor Detection" veri seti üzerinde eğitilen modelin, yeni MR görüntülerinde tümör varlığını (pozitif) ve yokluğunu (negatif) yüksek doğrulukla ayırt edebilmesini sağlamaktır. Bu bağlamda, modelin başarımleri analiz edilerek tıbbi görüntülemelerde yapay zeka tabanlı çözümlerin güvenilirliği değerlendirilmiştir.

2. YÖNTEM

Bu çalışmada, nesne tespiti amacıyla Ultralytics tarafından sağlanan 'Brain Tumor Detection' veri seti kullanılmıştır. Veri seti, beyin MR görüntülerini içermekte olup modelin eğitimi ve doğrulanması için `train` (893 adet) ve `valid` (223 adet) klasörleri altında yapılandırılmıştır.

Modelin eğitilmesi aşamasında, yüksek doğruluk ve hız performansı sağlayan transfer öğrenme (transfer learning) stratejisi benimsenmiştir. Bu kapsamda, YOLOv8 mimarisinin 'nano' versiyonu olan `yolov8n.pt` ön eğitilmiş ağırlıkları temel alınmıştır. Eğitim süreci, `brain-tumor.yaml` yapılandırma dosyası kullanılarak, 640x640 piksel görüntü boyutu ve 50 epoch (döngü) sayısı parametreleri ile Google Colab GPU ortamında gerçekleştirilmiştir.

3. BULGULAR VE TARTIŞMA

Bu çalışmada, YOLOv8 mimarisi kullanılarak gerçekleştirilen beyin tümörü tespiti modelinin eğitim süreci ve elde edilen performans metrikleri analiz edilmiştir.

3.1. Eğitim Performansı Eğitim süreci boyunca kaydedilen metrikler, modelin öğrenme kapasitesini yansıtmaktadır. `results.jpg` dosyasında sunulan öğrenme eğrileri incelendiğinde; `box_loss`, `cls_loss` ve `dfl_loss` değerlerinde 50 epoch boyunca düzenli bir düşüş gözlemlenmiştir. Bu durum, modelin veri setindeki özellikleri başarıyla öğrendiğini ve aşırı öğrenme (overfitting) belirtisi göstermeden yakınsadığını kanıtlamaktadır. Eğitim sonunda doğrulama seti üzerindeki kararlı `mAP@0.5` değerleri, modelin beyin tümörü tespiti konusunda yüksek bir genelleme başarısına sahip olduğunu göstermektedir.


4. DEĞERLENDİRME METRİKLERİ

Modelin performansını analiz etmek amacıyla kullanılan temel değerlendirme metrikleri aşağıda tanımlanmıştır:

- **Doğruluk (Accuracy):** Modelin tüm tahminleri içerisinde doğru sınıflandırdığı örneklerin oranıdır. Genel başarı göstergesidir.
- **mAP@0.5 ve mAP@0.5:0.95 (mean Average Precision):** Nesne tespiti modelleri için en kritik metriklerdir. mAP@0.5, 0.5 IoU (Intersection over Union) eşik değerinde hesaplanan ortalama kesinliktir. mAP@0.5:0.95 ise, 0.5 ile 0.95 arasındaki farklı eşik değerlerinde hesaplanan metriklerin ortalamasıdır; modelin hassasiyetini daha kapsamlı ölçer.
- **Kesinlik (Precision) ve Duyarlılık (Recall):** Kesinlik, modelin "pozitif" olarak tahmin ettiği verilerin ne kadarının gerçekte pozitif olduğunu; duyarlılık ise gerçek "pozitif" verilerin ne kadarını modelin yakalayabildiğini gösterir.
- **Karışıklık Matrisi (Confusion Matrix):** Modelin sınıflar (pozitif, negatif, background) arasındaki ayırım performansını gösteren tablodur. Hangi sınıfın hangisiyle karıştırıldığını (false positive/false negative) açıkça ortaya koyar.


Bu metrikler, eğitim süreci boyunca results.jpg dosyasında görselleştirilmiş ve modelin yakınsama (convergence) başarısı doğrulanmıştır.

-results.jpg




3.2. Sınıflandırma Başarısı Modelin tahmin yeteneğini değerlendirmek amacıyla oluşturulan Karışıklık Matrisi (Confusion Matrix), [confusion_matrix.png](#) dosyasında (buraya görseli ekle) sunulmuştur. Matris incelendiğinde, modelin "negatif" ve "pozitif" sınıfları arasındaki ayırım gücünün yüksek olduğu görülmektedir. Köşegen üzerindeki değerlerin yoğunluğu, modelin beyin tümörü olan vakaları ("pozitif") ve sağlıklı dokuları ("negatif") doğru sınıflandırma oranının oldukça yüksek olduğunu desteklemektedir. Elde edilen bu sonuçlar, YOLOv8 modelinin MR görüntülerinde tümör tespiti için güvenilir bir araç olduğunu ortaya koymaktadır.

-confusion_matrix



"Modelin sınıflar arası ayırım gücünü değerlendirmek amacıyla oluşturulan (Karışıklık Matrisi), modelin tahmin performansını ortaya koymaktadır. Köşegen üzerindeki değerler, modelin doğru sınıflandırma sayılarını temsil etmektedir. Matris incelendiğinde, 'pozitif' ve 'negatif' sınıflandırmalarda modelin belirgin bir başarı sergilediği görülmektedir. 'Background' sınıfı ile olan etkileşimler, modelin MR görüntülerindeki gürültüleri ayıklama kapasitesini yansıtmaktadır; yüksek değerlerin köşegen üzerinde yoğunlaşması, modelin güvenilirliğini desteklemektedir."

3.3. Niteliksel Analiz (Görsel Tahminler) Modelin doğrulama veri seti üzerindeki başarısını görsel olarak doğrulamak amacıyla yapılan tahmin analizleri aşağıda sunulmuştur. Bu görselde, modelin MR görüntüleri üzerindeki tümör bölgelerini başarıyla tespit ettiği ve 'bounding box' yöntemiyle işaretlediği görülmektedir.



5. SONUÇ

Bu çalışmada, beyin tümörü tespiti için YOLOv8 nesne tespiti mimarisi kullanılarak bir derin öğrenme modeli geliştirilmiştir. Elde edilen bulgular, modelin MR görüntüleri üzerinde yüksek doğrulukla tümör tespiti yapabildiğini ve tıbbi görüntüleme süreçlerinde bir "karar destek mekanizması" olarak kullanılabilecek potansiyele sahip olduğunu göstermektedir. Eğitim süreçleri sonucunda elde edilen mAP (mean Average Precision) ve diğer başarımlar metrikleri, modelin sağlıklı doku ile tümörlü dokuyu ayırt etmede başarılı bir performans sergilediğini doğrulamıştır. Niteliksel analiz kapsamında görselleştirilen örnek tahminler (bounding box çıktıları), modelin klinik benzeri koşullarda tutarlı sonuçlar üretebildiğini desteklemektedir. Gelecek çalışmalarda, daha geniş ve çeşitlendirilmiş bir veri seti kullanılarak modelin genelleme yeteneğinin artırılması ve farklı tümör tiplerine yönelik (multi-class) tespitlerin yapılması hedeflenmektedir. Bu proje, derin öğrenme tekniklerinin tıbbi teşhis süreçlerini hızlandırma ve doğruluk oranlarını iyileştirme konusundaki kritik rolünü bir kez daha ortaya koymuştur.